

# **TuneSight – Democratizando Talentos na Indústria Musical**

**Maeli P. de Melo<sup>1</sup>, Victor H. do Nascimento<sup>1</sup>, Rosemeiry de Castro P. Maximiano<sup>1</sup>, Robson P. Bonidia<sup>2</sup>**

<sup>1</sup> Departamento de Ciência de Dados – Faculdade de Tecnologia de Ourinhos, Av. Vitalina Marcusso, 1440, Campus Universitário – Ourinhos – SP – Brasil.

<sup>2</sup> Departamento de Ciência da Computação, Universidade Tecnológica Federal Paraná — UTFPR, Cornélio Procópio, Paraná, Brasil

**Abstract.** *This research aims to assist independent artists in overcoming the challenges of gaining recognition in the music industry, including financial constraints, limited access to professional infrastructure, and competition in the digital environment. This study developed a model that utilizes artificial intelligence to predict the success of songs by employing machine learning techniques for the development of a chatbot called TuneSight. The model achieved an accuracy of 66% in predicting success with test data. This level of accuracy offers a considerable degree of confidence for independent artists to reflect on how to more effectively promote their music. TuneSight proved to be an effective tool to support decision-making in the music industry. By using the chatbot, independent artists can focus more on improving and enhancing their songs.*

**Resumo.** *A presente pesquisa tem como objetivo auxiliar artistas independentes a enfrentar os desafios de reconhecimento na indústria musical, incluindo limitações financeiras, dificuldades de acesso a infraestrutura profissional e a competição no ambiente digital. Trata-se de um estudo no qual foi desenvolvido um modelo que utiliza aprendizado de máquina para prever o sucesso de músicas por meio de um chatbot chamado TuneSight. O modelo alcançou uma acurácia de 66% na previsão de sucesso com os dados de teste, oferecendo um grau de confiança considerável para que artistas independentes possam tomar decisões mais informadas sobre a promoção de suas músicas. O TuneSight se mostrou uma ferramenta eficaz para apoiar a tomada de decisões na indústria*

*musical. Com o uso do chatbot, os artistas independentes podem focar mais na melhoria e aprimoramento de suas músicas.*

## **1 Introdução**

A indústria musical é um setor diversificado que abrange a criação, produção, distribuição e promoção de música, incluindo gravadoras, editoras e plataformas digitais. Historicamente dominada por grandes gravadoras, a indústria tem passado por uma transformação significativa com o advento das tecnologias digitais e das plataformas de streaming, que agora representam uma parte substancial de sua receita. Segundo o Relatório Global de Música da *International Federation of the Phonographic Industry* (IFPI), o mercado de música gravada cresceu cerca de 9% em 2022, com o streaming respondendo por aproximadamente 67% dessa receita. (IFPI, 2022).

Na indústria musical, artistas independentes são músicos ou bandas que produzem e distribuem suas músicas de forma autônoma, sem o apoio de grandes gravadoras. Esses artistas frequentemente financiam seus próprios projetos e utilizam plataformas digitais e redes sociais para promover seu trabalho. Conforme a MIDiA Research. (2023), a distribuição direta ao consumidor representa uma fatia significativa do mercado musical, permitindo que artistas independentes alcancem audiências globais e mantenham maior controle sobre suas carreiras.

Apesar das oportunidades, os artistas independentes enfrentam desafios significativos. Eles muitas vezes precisam autofinanciar gravações e produções, o que pode ser um obstáculo considerável. Além disso, a falta de acesso à infraestrutura profissional, como estúdios de gravação e campanhas de *marketing*, limita suas capacidades de promoção. Como observado por Soundcharts (2023), a ausência de conexões na indústria musical pode dificultar a visibilidade e o sucesso dos artistas independentes.

A diversidade que os artistas independentes trazem para a indústria musical é crucial, já que eles frequentemente experimentam sons inovadores e abordagens criativas. Isso enriquece o panorama musical e abre espaço para a descoberta de talentos emergentes. De acordo com Music Business Worldwide (2023) o aumento da presença digital e da independência criativa permite que esses músicos ampliem suas audiências e mantenham controle sobre suas obras.

Para maximizar suas chances de sucesso, os artistas independentes podem se beneficiar de modelos preditivos que identifiquem o potencial de sucesso de suas músicas. Esses modelos podem ajudá-los a focar em faixas com maior probabilidade de impacto comercial, otimizando seus investimentos de tempo e recursos em produção e marketing. Conforme indicado por Berklee Online (2023), ao usar ferramentas de previsão mais precisas, artistas independentes podem tomar decisões mais informadas, reduzindo riscos financeiros e aumentando suas oportunidades de sucesso em um mercado competitivo.

Para ajudar artistas independentes a maximizar seu potencial de sucesso no mercado competitivo, propomos o TuneSight<sup>1</sup>. Desenvolvido como uma ferramenta prática e acessível, o TuneSight utiliza um modelo de Aprendizado de Máquina (AM) que analisa diversos aspectos musicais para fornecer feedback rápido sobre a probabilidade de uma faixa se tornar um hit. Com essa ferramenta, artistas independentes podem otimizar o investimento de tempo e recursos, concentrando-se em músicas com maior potencial comercial e aumentando suas chances de alcançar o sucesso.

## 2 Revisão de Literatura

Para iniciar o estudo sobre predição de hits musicais, foi aplicado uma revisão da literatura utilizando as palavras-chave: “*Predicting Hits*”, “*Songs and Machine Learning*”, “*Predicting Songs with Machine Learning*”. As buscas retornaram alguns artigos no mesmo tema com diversas perspectivas. Na tabela a seguir, é apresentado um resumo sobre os artigos encontrados:

*Tabela 1 - Comparativo de Artigos Relacionados*

Artigos	Resumo
Merrit, S.H.; Gaffuri, K. e Zak; P.J. (2023)	Utiliza técnicas de AM e a neurofisiologia para prever o sucesso das músicas.

---

<sup>1</sup> [https://t.me/tunesight\\_bot](https://t.me/tunesight_bot)

Minna, R., Philippa, O. (2018)	Exploram a viabilidade de prever músicas de sucesso utilizando características de áudio e algoritmos de AM, como Regressão Logística e <i>Support Vector Machine</i> .
Khan, F.; Tarimer, I.; Alwageed, H.S.; Karadağ, B.C.; Fayaz, M.; Abdusalomov, A.B.; Cho, Y.-I. (2022)	Aplicam a seleção de características de áudio influência para classificação da popularidade de músicas utilizando algoritmos de AM, como <i>Random Forest</i> e KNN ( <i>K-Nearest Neighbors</i> ).
André, A.B. (2021)	Análise de músicas brasileiras contemporâneas para identificar padrões que possam prever o sucesso musical utilizando algoritmos de AM.

Embora existam estudos sobre a predição de sucesso musical com AM, o TuneSight se destaca como um projeto ativo em 2024, que incorpora dados e técnicas de Aprendizado de Máquina de última geração para aprimorar seu algoritmo preditivo. Sua inovação não se limita à tecnologia empregada, mas reflete um compromisso com a democratização de ferramentas analíticas acessíveis, projetadas especificamente para artistas independentes.

Um diferencial importante do TuneSight é sua base de dados personalizada, que extrai características únicas de áudios musicais relevantes, elevando a precisão das previsões. Com um modelo preditivo de fácil acesso, os artistas independentes podem enviar suas músicas para análise mediante um chatbot no Telegram, tornando o processo simples e conveniente.

Essa democratização da predição de sucesso musical representa uma transformação significativa na indústria, capacitando artistas a tomarem decisões fundamentadas em dados, sem a necessidade de apoio de grandes gravadoras. Orientados pelo TuneSight para identificar faixas com maior potencial de impacto, os músicos podem otimizar suas produções, concentrar-se em criações de maior retorno e reduzir riscos financeiros.

### 3 Materiais e Métodos

Nesta seção, será detalhado o processo metodológico adotado para o desenvolvimento do projeto, que visa criar um modelo de AM adaptado em um *chatbot* para prever a probabilidade de sucesso de músicas. A metodologia aplicada foi planejada desde a coleta e pré-processamento dos dados de áudio até a criação do *chatbot* e a integração do modelo na forma de uma *Application Programming Interface* (API) para interação com o usuário final.

#### 3.1 Tecnologias Utilizadas

Para a execução deste projeto, foi essencial a escolha das tecnologias e ferramentas, garantindo que cada uma delas atendesse às necessidades específicas de desenvolvimento. As ferramentas selecionadas foram fundamentais para a construção de todo o projeto, entre elas:

- **Python:** Uma linguagem de programação de fácil aprendizado e código aberto. A linguagem oferece diversos recursos para análise de dados, desenvolvimento de modelos de AM;
- **Pytube:** Biblioteca utilizada para baixar vídeos do YouTube em Python. Ela facilita o download e a manipulação de vídeos diretamente da *Uniform Resource Locator* (URL), permitindo o uso de conteúdo de vídeo e áudio em diversos formatos. Ela foi utilizada para baixar as músicas selecionadas para criar o conjunto de dados em formato de vídeo (mp4);
- **Pydub:** Biblioteca Python utilizada para manipulação de áudio. Ela permite operações como conversão de formatos, corte, ajuste de volume e mixagem de áudio, facilitando o pré-processamento dos arquivos de áudio. Foi aplicada para transformar os arquivos em mp4 para áudios em formato mp3;
- **Librosa:** Biblioteca especializada em análise de áudio e música. Ela facilita a extração de características de áudio.
- **Numpy:** Biblioteca essencial para operações numéricas em Python, especialmente com *arrays* e matrizes. Ela oferece suporte para cálculos matemáticos complexos, sendo amplamente utilizada em conjunto com outras

bibliotecas. Ela foi utilizada para ajustar os valores das características extraídas pelo Librosa;

- **Pandas:** Biblioteca poderosa para manipulação e análise de dados. Ela fornece estruturas de dados flexíveis como *DataFrames*. Essa biblioteca foi fundamental para organizar e analisar grandes volumes de dados de maneira eficiente, como, por exemplo, os conjuntos de dados criados;
- **Scikit-Learn:** Biblioteca robusta para AM em Python. Ela fornece ferramentas para classificação, regressão, clustering, e muito mais, além de oferecer suporte para o pré-processamento de dados e avaliação de modelos, auxiliando no desenvolvimento do TuneSight;
- **Botpress:** Plataforma de código aberto para construir e gerenciar *chatbots*. Ele foi utilizado no desenvolvimento do TuneSight para facilitar a interação com os usuários e integrar o modelo de previsão ao *bot*;
- **Miniconda:** Uma distribuição mínima do Anaconda que inclui apenas o gerenciador de pacotes conda e seus dependentes. Ele foi utilizado para gerenciar ambientes Python, garantindo a compatibilidade e organização das bibliotecas no desenvolvimento do TuneSight;
- **Postman:** Ferramenta de colaboração para testar e desenvolver APIs. Ele foi utilizado para testar a API criada no TuneSight, facilitando a validação das interações entre o bot e os serviços de *backend*;
- **Flask:** Micro *framework* de web em Python. Ele foi utilizado no TuneSight para criar a API de forma simples e eficiente, permitindo a integração do modelo de AM com a interface do usuário e o *bot*.

### 3.2 Conjunto de Dados

Para o desenvolvimento do conjunto de dados, foi feita a escolha das músicas que seriam utilizadas para a criação do modelo de AM. Para essa seleção foram utilizadas bases de dados disponibilizados na plataforma Kaggle, sendo elas, uma base de dados com um milhão de músicas de diversos anos e outras duas bases de dados contendo músicas de 2023 e 2024 para complementar a base inicial.

A partir dessa base de dados inicial, foram extraídas apenas as colunas de nome da música, nome do artista e popularidade. Esta última foi transformada em uma coluna binária para indicar se a música seria classificada como Não Hit (0), quando a popularidade era menor que 60, ou Hit (1), quando a popularidade era maior. No total, 300 músicas por ano foram selecionadas, sendo 200 classificadas como Não Hit e 100 como Hit. Com esses dados preliminares, foram realizados os downloads dos áudios das músicas para construir o conjunto de dados. Em seguida, características de áudio foram coletadas, além do pré-processamento, garantindo que os arquivos estivessem corretamente formatados e prontos para análise. Após a preparação, o conjunto de dados foi dividido em treino, contendo 7.456 amostras, e teste, com 260 amostras. As músicas para o teste foram selecionadas aleatoriamente em grupos de 10 a cada 300, assegurando uma validação robusta do treinamento do modelo.

### 3.3 Representação Numérica

Para converter as músicas em representações numéricas utilizáveis pelos algoritmos de AM, foram extraídas características que capturam aspectos essenciais do áudio utilizando a biblioteca Librosa, o que facilitou o processo de modelagem. As características extraídas incluem:

- **length:** A duração do áudio em segundos;
- **chroma\_stft:** Representa as características cromáticas extraídas usando a Transformada de Fourier de Curto Prazo (STFT). As características cromáticas capturam a energia das notas musicais ao longo do tempo;
- **chroma\_cqt:** É similar ao **chroma\_stft**, mas usando a Transformada de Fourier Constante (CQT). CQT é útil para capturar melhor as frequências baixas e altas;
- **chroma\_cens:** Representa uma versão mais suave das características cromáticas, sendo menos sensível ao ruído e pequenas variações;
- **chroma\_vqt:** Representa as características cromáticas extraídas usando uma Transformada de Fourier de Q variável (VQT), que permite uma maior resolução nas frequências baixas e uma menor nas frequências altas;

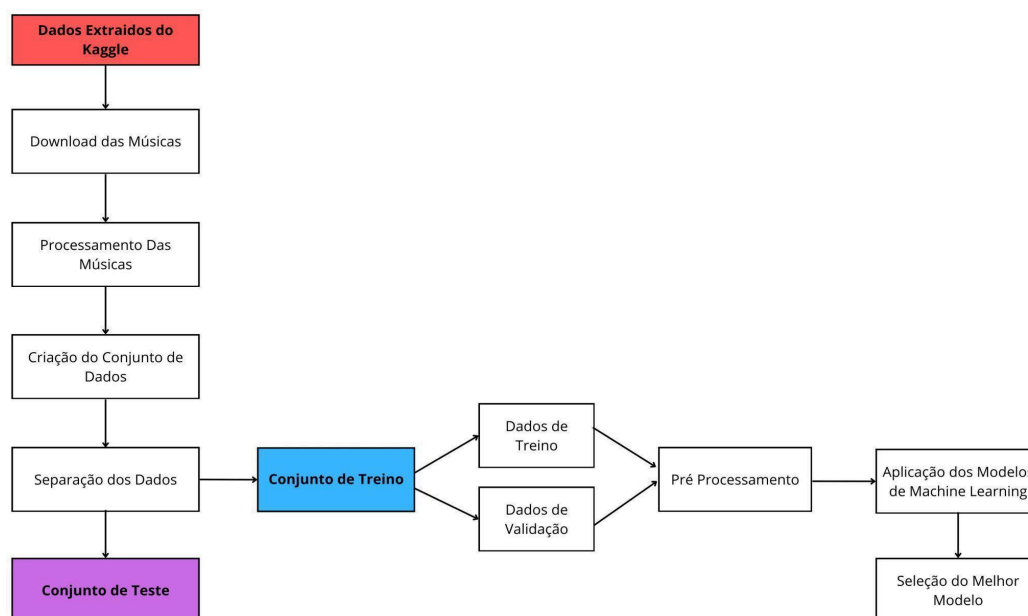
- **melspectrogram:** Representa a distribuição de energia ao longo de diferentes bandas de frequência usando a escala mel, baseada na percepção humana do som;
- **mfcc:** Representa o Coeficiente Central de Frequência Mel, usado para representar as características mais importantes do timbre de um som. Eles são obtidos transformando o sinal de áudio em pequenas partes, convertendo-as e ajustando-as para uma escala que imita como o ouvido humano percebe o som;
- **rms:** Representa a raiz quadrada média da amplitude do áudio, representando a energia do sinal;
- **spectral\_centroid:** Representa o "centro de massa" do espectro, indicando a frequência média ponderada pelo conteúdo de energia;
- **spectral\_bandwidth:** Representa a largura da banda do espectro, ou seja, a faixa de frequências onde está concentrada a maioria da energia;
- **spectral\_contrast:** Mede a diferença entre as partes mais altas e mais baixas do espectro;
- **spectral\_flatness:** Mede o quão "plano" ou "rico em tons" é o espectro. Um valor alto indica um espectro relativamente plano, similar a um ruído branco;
- **spectral\_rolloff:** Representa a frequência abaixo da qual se encontra uma determinada percentagem do espectro acumulado, normalmente 85%;
- **poly\_features:** Representa os coeficientes dos polinômios ajustados ao espectro do áudio, úteis para capturar a forma do espectro;
- **tonnetz:** Representa o espaço tonal, capturando relações harmônicas e frequências de notas;
- **tempo:** Estima a velocidade da música em batidas por minuto (BPM);
- **tempogram:** Representa a evolução temporal do ritmo da música ao longo do tempo;
- **tempogram\_ratio:** Representa a razão das frequências principais no tempogram, indicando a estrutura rítmica predominante.

### 3.4 Configuração Experimental

O objetivo central da idealização deste projeto foi desenvolver uma ferramenta capaz de prever a probabilidade de uma música se tornar um hit, aproveitando uma coleção robusta de dados construída especificamente para essa finalidade, como



ilustrado anteriormente. O fluxo de trabalho na Figura 1 detalha as diversas etapas realizadas, desde a seleção e processamento dos dados até a criação e treinamento do algoritmo preditivo.



*Figura 1 - Fluxo de trabalho para modelagem do TuneSight.*

Inicialmente, foi essencial definir e coletar características musicais relevantes, transformando dados brutos em representações numéricas que pudessem ser analisadas pelos modelos de AM. Essas etapas incluíram desde a extração de áudio até o pré-processamento dos dados, assegurando que a estrutura final fosse adequada para uma análise robusta. Posteriormente, o desenvolvimento do algoritmo preditivo buscou integrar essas características de maneira otimizada, visando alcançar previsões precisas e confiáveis sobre o potencial de sucesso das músicas.

## 4 Resultados e Discussão

Para selecionar o modelo ideal para o desenvolvimento do TuneSight, foi aplicada uma abordagem para treinar vários algoritmos e analisar quais os cinco melhores modelos para testes mais aprofundados, conforme apresentado na Tabela 2:

**Tabela 2- Resultado Dos Modelos Preliminares**

<b>Classificador</b>	<b>Acurácia</b>	<b>Acurácia Bal.</b>	<b>Precisão Hit</b>	<b>Precisão Não Hit</b>
<i>Catboost</i>	0.779	0.669	0.420	0.920
<i>Decision Tree</i>	0.745	0.661	0.470	0.850
<i>KNN</i>	0.756	0.695	0.560	0.830
<i>Logistic Regression</i>	0.777	0.687	0.480	0.890
<i>Naive Bayes</i>	0.720	0.500	0.000	1.000
<i>Random Forest</i>	0.774	0.649	0.370	0.930
<i>SVM</i>	0.780	0.686	0.470	0.900
<i>XGBoost</i>	0.792	0.708	0.520	0.900

Com esses resultados, foi realizada a seleção dos modelos XGBoost, KNN, Regressão Logística, SVM e CatBoost para avançar nos testes. A partir dessa seleção, foi conduzido um experimento de aprimoramento, aplicando diversas técnicas de pré-processamento e otimização de parâmetros, visando maximizar o desempenho dos modelos. As principais abordagens utilizadas incluem:

#### **4.1 Remoção dos Outliers**

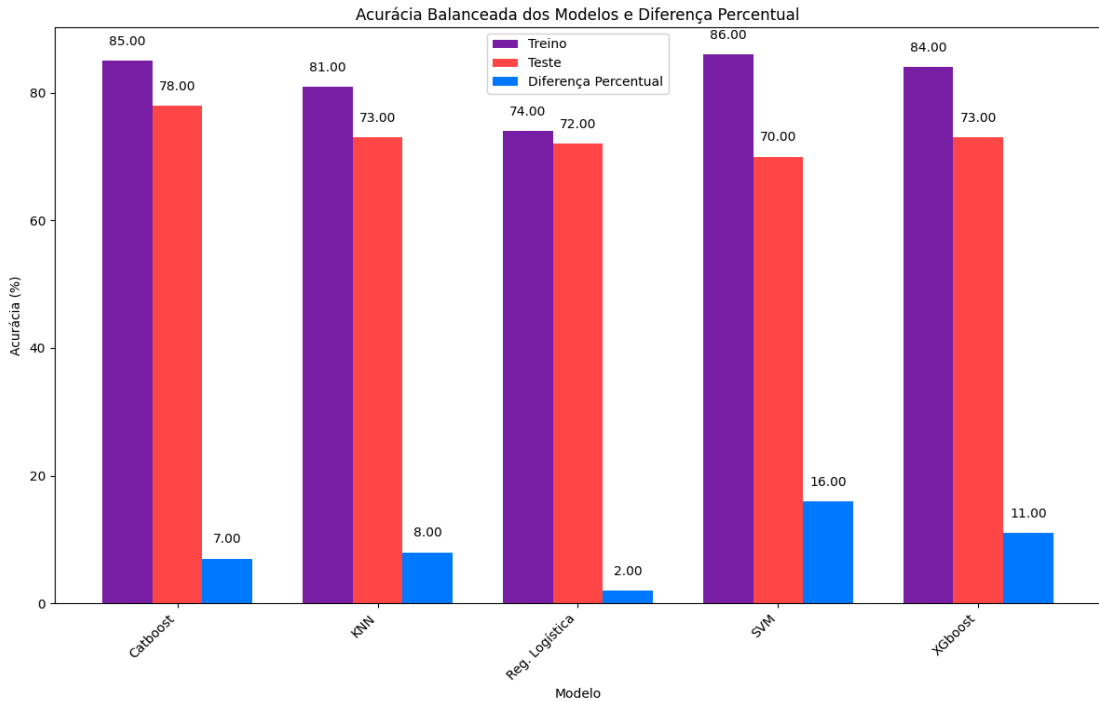
*Outliers* que poderiam impactar negativamente o desempenho dos modelos foram removidos. Para isso, foi aplicado uma função que utiliza a regra do intervalo interquartil (IQR) para identificar outliers em cada coluna numérica. Essa função calcula o primeiro quartil (Q1) e o terceiro quartil (Q3) da coluna e determina o IQR (diferença entre Q3 e Q1). Em seguida, ela define os limites inferior e superior para identificar outliers, definidos como valores fora do intervalo. Valores abaixo do limite inferior ou acima do limite superior foram considerados *outliers*. A fim de remover os casos mais extremos, foram removidos os 5% dos registros com mais *outliers*.

## 4.2 Balanceamento das Classes

Devido ao desbalanceamento presente nas classes do conjunto de dados, foi utilizada a técnica Synthetic Minority Over-sampling Technique (SMOTE) para gerar novas instâncias da classe minoritária, de modo a alcançar 75% do número de amostras da classe majoritária. Essa abordagem foi fundamental para reduzir o viés dos modelos, garantindo um aprendizado mais robusto e equilibrado entre as classes.

## 4.3 Hiperparâmetros

Os modelos foram ajustados utilizando o framework Optuna para a busca de hiperparâmetros, otimizando o treinamento para alcançar o melhor desempenho possível. Essa técnica permitiu uma exploração eficiente de um espaço de parâmetros complexo, resultando na seleção das configurações ideais para cada modelo, conforme ilustrado na Figura 2.




*Figura 2 - Métricas do treinamento dos melhores modelos após ajuste dos hiperparâmetros*

## 4.3 Modelo Final


As etapas anteriores foram cruciais para melhorar a qualidade dos dados e otimizar o processo de aprendizado dos modelos, permitindo uma avaliação mais precisa de seu desempenho nas fases subsequentes de teste. Com base nessa análise, o CatBoost foi selecionado como o modelo final, considerando a relação entre a acurácia balanceada e a diferença percentual entre os conjuntos de treino e teste.

O CatBoost apresentou resultados satisfatórios, embora tenha mostrado uma diferença no desempenho da predição dos hits entre treino e teste. Essa diferença pode ser atribuída à complexidade inerente ao problema abordado: a natureza dos dados torna a tarefa de classificação especialmente desafiadora, e a presença de padrões complexos dificulta a separação clara entre as classes. Esse contexto ressalta a importância de métodos robustos para lidar com as nuances dos dados.

Para uma análise mais profunda, as Figuras 3 e 4 apresentam as matrizes de confusão para os conjuntos de treinamento e teste, respectivamente. Essas matrizes permitem visualizar os verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos, auxiliando na avaliação da capacidade do modelo em prever corretamente as diferentes classes.

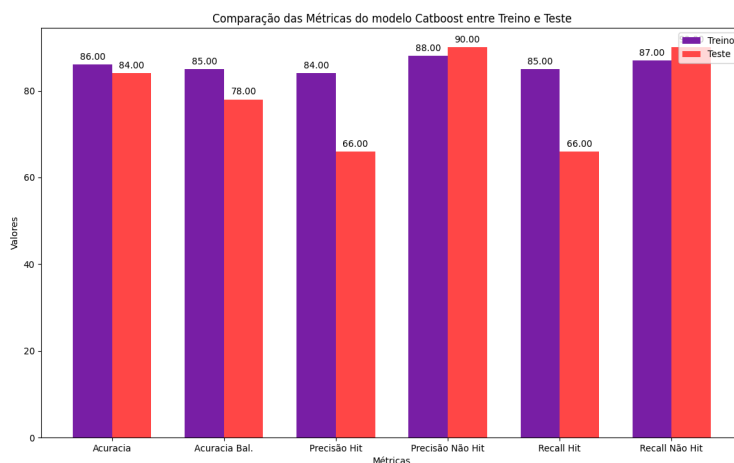


*Figura 3 - Matriz de Confusão do Treinamento do Modelo*



**Figura 4 - Matriz de Confusão do Teste do Modelo**

Adicionalmente, as métricas de precisão e recall apresentadas na Figura 5 demonstram que o modelo conseguiu identificar os *Hits* com uma relevância significativa. Assim, pode-se concluir que o modelo de AM apresenta uma precisão superior ao que seria esperado ao acaso. Isso permite que ele contribua na análise de artistas independentes ao lançarem suas músicas, o qual é o objetivo central deste artigo.



**Figura 5 - Comparação das Métricas do Modelo Catboost entre Treino e Teste**

Com base nos resultados apresentados, o Catboost demonstrou ser uma escolha relativamente eficaz para a predição de hits. A queda na precisão dos hits no conjunto de teste sugere que algumas instâncias da classe positiva não estão sendo identificadas, mas isso não compromete a utilidade prática do modelo devido à acurácia ainda ser relevante.

#### 4.4 Apresentação do TuneSight

O desenvolvimento do TuneSight foi realizado com o Botpress, uma plataforma de código aberto para criação e gerenciamento de chatbots. O funcionamento do TuneSight ocorre mediante uma programação baseada em cards no Botpress, onde o chatbot se comunica com o cliente por meio de mensagens padrão. Após as validações iniciais e o envio do áudio, uma verificação é realizada para confirmar que o arquivo foi enviado no formato MP3. Em caso positivo, os dados são enviados via API para o servidor, onde são executadas as seguintes etapas:

1. **Coleta de Dados:** O servidor recebe os dados via API e realiza o *download* da música;
2. **Processamento dos Dados:** É realizada a extração de características da música com a biblioteca Librosa para realizar a análise do áudio;
3. **Análise:** Com os dados processados, o modelo de AM classifica a música e fornece uma porcentagem dela ser *Hit*;
4. **Resultados:** O resultado é retornado ao Botpress via API e o mesmo retorna ao usuário um texto informando a probabilidade classificada.

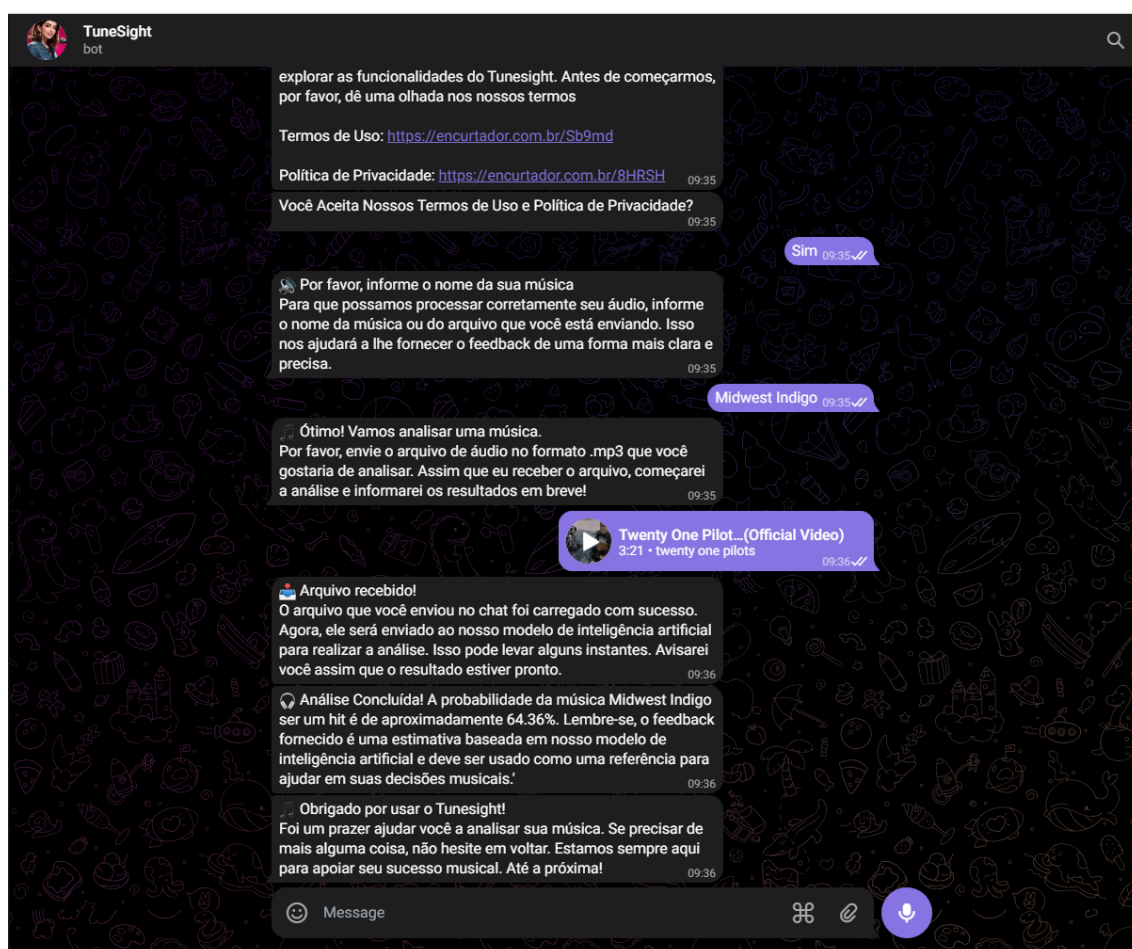
A Figura 6 fornece uma visão de cada etapa do funcionamento do TuneSight, desde a coleta de dados até a análise dos resultados. Essas etapas são essenciais para garantir que o sistema opere de maneira eficiente e forneça o resultado sobre as músicas analisadas

## 5 Conclusão

Em resumo, a pesquisa evidenciou a relevante influência dos artistas independentes no cenário musical atual, onde a diversidade e a inovação em suas criações enriquecem a cultura com novas perspectivas e expressões autênticas. No

entanto, enfrentam diversos obstáculos na indústria musical, como a falta de marketing e promoção. A variedade de métricas e algoritmos abordados ao longo do trabalho oferecem uma gama de oportunidades que podem apoiar os artistas independentes na superação dos desafios do mercado, ajudando-os a alcançar seu potencial.

Por meio da análise de grandes volumes de dados e da identificação de padrões, é possível extrair características essenciais que definem o sucesso de uma música. O trabalho também explora a diversidade de métricas e algoritmos disponíveis, ressaltando a importância do desenvolvimento de modelos preditivos eficazes.



*Figura 6 - Funcionamento do chatbot, envio do áudio e apresentação do resultado*

Assim, a pesquisa não apenas contribui para a compreensão do impacto dos artistas independentes, mas também enfatiza a relevância de tecnologias emergentes na evolução da indústria musical.

## Referências

Amar. S. (2023). Impacto da Inteligência Artificial na Indústria Musical e nos Direitos Autorais. Disponível em: <https://amar.art.br/impacto-da-inteligencia-artificial-na-industria-musical-e-nos-direitos-autorais/>. Acesso em 01 de Junho de 2024.

Ana, C.D.M, Camila, M., Gabriel, C., Gabriela, O., Gabriela, S. (2021). Artistas independentes: as dificuldades de viver da arte na cidade de São Paulo. Disponível em: <https://laboratoriodejo2021.medium.com/artistas-independentes-as-dificuldades-de-viver-da-arte-na-cidade-de-sao-paulo-149420acdc79>. Acesso em 01 de Junho de 2024.

André, A.B. (2021). Avaliação de características e previsão de sucesso de canções populares brasileiras por meio de Aprendizado de Máquina. Universidade Federal de Goiás. Disponível em: <https://repositorio.bc.ufg.br/teseserver/api/core/bitstreams/dc4b41d7-3830-4cb8-a15c-f84856d09d84/content>. Acesso em 09 de Outubro de 2023.

Batu, Y. (2021). Getting Lyrics of Songs via Python (LyricsGenius). Disponível em: <https://medium.com/analytics-vidhya/getting-lyrics-of-songs-via-python-lyricsgenius-23e5dd5992e3>. Acesso em 23 de Março de 2024.

Berklee Online. (2023). Music Business Courses. Disponível em: <https://online.berklee.edu>. Acesso em: 21 de Setembro de 2024.

D. N. Raju; A. Thilagavathy; B. Ekshitha; N. Kedari; G. H. Naidu and V. G. Reddy (2023) Adaptive Multi-Variate Deep Learning Model for Music Hit Prediction: A Systematic Review. Third International Conference on Artificial Intelligence and Smart Energy (ICAIS), Coimbatore, India, pp. 516-522, doi: 10.1109/ICAIS56108.2023.10073785.

David, C. (2023). Converting Speech to Text with Spark NLP and Python. Disponível em:



<https://www.johnsnowlabs.com/converting-speech-to-text-with-spark-nlp-and-python/>.

Acesso em 09 de Março de 2024.

Equipe, P. (2017). Artistas independentes: as dificuldades em viver de música no Brasil. Disponível em:

<https://jornalismorio.espm.br/geral/artistas-independentes-dificuldades-em-viver-de-musica-no-brasil/>. Acesso em 01 de Junho de 2024.

Ernesto, L. (2023). Transforming Audio to Text with OpenAI's Speech-to-Text API: A Practical Step-by-Step Guide. Convert Zoom and WebEx and any Audio File! Disponível em:

<https://ernestodotnet.medium.com/transforming-audio-to-text-with-openais-speech-to-text-api-a-practical-step-by-step-guide-8139e4e65fdf>. Acesso em 09 de Março de 2024.

IFPI. (2022). Global Music Report 2022. Disponível em: <https://www.ifpi.org/ifpi-global-music-report-2022/>. Acesso em: 21 de Setembro de 2024.

Jagdish, K. (2023). Using OpenAI whisper python library for speech to text. Disponível em: <https://medium.com/@kharatmoljagdish/using-openai-whisper-python-library-for-speech-to-text-dda4f558fccc>. Acesso em 09 de Março de 2024.

Julia, V. (2023). Democratização da indústria musical não é garantia de sucesso. Disponível em: <https://jornal.usp.br/campus-ribeirao-preto/democratizacao-da-industria-musical-nao-e-garantia-de-sucesso/>. Acesso em 01 de Junho de 2024.

Khan, F.; Tarimer, I.; Alwageed, H.S.; Karadağ, B.C.; Fayaz, M.; Abdusalomov, A.B.; Cho, Y.-I. (2022). Effect of Feature Selection on the Accuracy of Music Popularity Classification Using Machine Learning Algorithms. Electronics 11, 3518.

<https://doi.org/10.3390/electronics11213518>.

Merrit, S.H., Gaffuri, K. and Zak, P.J. (2023). Accurately predicting hit songs using neurophysiology and machine learning. *Front. Artif. Intell.* 6:1154663. doi: 10.3389/frai.2023.1154663.

MIDiA Research. (2023). Music Market Reports. Disponível em: <https://www.midiaresearch.com>. Acesso em: 21 de Setembro de 2024.

Minna, R., Philippa, O. (2018). Predicting Hit Songs with Machine Learning. Stockholm, Sverige. Disponível em: <https://www.diva-portal.org/smash/get/diva2:1214146/FULLTEXT01.pdf>. Acesso em 22 de Outubro de 2023.

Music Business Worldwide. (2023). Music Industry News. Disponível em: <https://www.musicbusinessworldwide.com>. Acesso em: 21 de Setembro de 2024.

Rafaella, A. R. (2024). Os desafios enfrentados por artistas independentes na indústria musical. Disponível em: <https://labnoticias.jor.br/2024/04/29/os-desafios-enfrentados-por-artistas-independente-s-na-industria-musical/>. Acesso em: 01 de Junho de 2024.

RAJEEV, N. (2021). SVM-Hyperparameter Tuning. Disponível em: <https://www.kaggle.com/code/rajeevnair676/svm-hyperparameter-tuning>. Acesso em 20 de Abril de 2024.

Robert. E.V. (2013). Does Chatter Matter? Predicting Music Sales with Social Media. University of Southern California. Disponível em: <https://www.basichthinking.de/blog/wp-content/uploads/2013/06/Does-Chatter-Matter.pdf>. Acesso em 14 de Outubro de 2023.

Soundcharts. (2023). Blog. Disponível em: <https://soundcharts.com/blog>. Acesso em: 21 de Setembro de 2024.